

A5 vs A3 · 网络通信能力对比

Ascend 950 (NPU arch 3510) vs Ascend 910C (arch 2201) · 灵衢 UnifiedBus 2.0 带来「面向超节点的内存语义通信」

Ascend A3 · 910C

scale-up 由 HCCS 承载 · scale-out 走 RoCE · 消息式集合通信

784 GB/s

HCCS 聚合互联带宽


微秒级

单跳链路时延

384

CloudMatrix 集群 (NPU)

互联拓扑



RoCEv2 (100G×2) scale-out · 跨机箱需交换机，多跳

定位：以「算」为核心

跨节点依赖交换机 + 消息式通信；KV/ 权重需多跳或回 CPU 内存

Ascend A5 · 950

灵衢 UnifiedBus(UB) 2.0 全光直连 · URMA 单边 + Load/Store 内存语义

2 TB/s

互联带宽 $\approx 2.5 \times 910C$


200 ns

单跳时延 $\approx$ 降低 10×

8192

Atlas 950 超节点 (NPU)

互联拓扑



UB-Mesh 递归直连 · 单柜 64 卡 $\rightarrow$ 8192 卡超节点 · URMA 单边读写远端内存

定位：以「域」为核心 (类比：超节点 $\approx$ 一台大机器)

互联即内存：URMA 单边 + 统一编址，直接读写远端 HBM

A5 vs A3 · 网络通信四大差异

世界变了：从「板内小互联」到「超节点大互联」——通信从消息式走向单边内存语义

差异维度	Ascend A3 · 910C (arch 2201)	Ascend A5 · 950 (arch 3510)
① 互联总线 与拓扑	HCCS 板内直连 (~784 GB/s) scale-out 走 RoCEv2/PCIe ，需交换机	灵衢 UnifiedBus(UB) 2.0 全光直连 (2 TB/s) UB-Mesh 递归全网状，三级 (板 / 柜 / 架)
② 通信模型 与语义	消息传递为主：HCCL/HCOMM 集合通信 (AllReduce/ReduceScatter/AllGather)	URMA 单边 (one-sided) 读写 同时支持 Load/Store 同步 & URMA 异步消息双语义
③ 内存 / 地址 语义	无跨卡统一编址 远端访问 = 多跳 / 显式消息，KV/ 权重常回 CPU	SHMEM 全域内存语义 + 统一编址 / 内存池化 KV Cache 可放远端 HBM ，一条 URMA Read 拉回
④ 时延与 带宽量级	单跳 ~2μs、跨柜 ~7μs 互联带宽 784 GB/s	单跳 ~200 ns (↓ 10× ，仅指单跳)、跨柜 ~3 μs 互联带宽 2 TB/s (≈ 2.5× 910C)

一句话总结：

A5 的「网络」不再只是外围通信管道，更像超节点的循环系统（类比）——通过 UB 2.0 + URMA/SHMEM 把多台机器变成统一编址的「一台大机器」，通信从消息式转向内存语义，这是 A3→A5 最本质的网络变化。

来源：华为官方超节点 / 灵衢 2.0、Hot Chips 2025 UB-Mesh 演讲、CANN 面向 950 架构详解（URMA/Entity/UMMU/UBFM）；hcomm(ascend950 CCU/mc2) 与 hixl 本地仓佐证。